پروژه ی تحلیل داده

فاز اول

ریحانه سلیمانی مقدم

403100151

الزامات مشترک:

- سه سوال اولیه:

سؤال ۱ ـ تحلیل اکتشافی: چه الگوها و موضوعات پرتکراری در متن نقدهای محصولات Beauty & Personal Care وجود دارد؟

سؤال ۲ ـ تحلیل ارتباطی: چه رابطه‌ای میان ویژگی‌های ساخت‌یافته‌ی نقد و محصول، مانند امتیاز نقد و ویژگی‌های محصول، با تعداد رأی‌های مفید وجود دارد؟

سؤال ۳ ـ پیش‌بینی و یادگیری ماشین: آیا ترکیب ویژگی‌های متنی نقدها و اطلاعات ساخت‌یافته‌ی نقد و محصول می‌تواند دقت پیش‌بینی تعداد رأی‌های مفید را نسبت به استفاده‌ی جداگانه از هر منبع اطلاعاتی بهبود دهد؟

- صورت بندی مسئله:

هدف این پژوهش بررسی عوامل مؤثر بر مفید بودن Reviewهای محصولات آرایشی و بهداشتی در آمازون است. مسئله اصلی، پیش‌بینی تعداد رأی‌های مفید (`helpful_vote`) بر اساس متن Review و ویژگی‌های مرتبط با آن است. نتایج می‌تواند مشخص کند چه ویژگی‌هایی با مفیدتر تلقی شدن Reviewها ارتباط دارند. این تحلیل می‌تواند به پلتفرم‌های فروش آنلاین در بهبود نمایش و رتبه‌بندی Reviewها کمک کند.

- شناخت منشاء داده:

منبع داده، مجموعه‌داده‌ی Amazon Reviews'23 منتشرشده توسط McAuley Lab دانشگاه UC San Diego است که شامل Reviewها و اطلاعات محصولات آمازون می‌شود. داده‌ها به‌صورت مشاهده‌ای و از تعاملات کاربران با محصولات جمع‌آوری شده‌اند و حاصل آزمایش کنترل‌شده نیستند. بازه‌ی زمانی Reviewها از مه ۱۹۹۶ تا سپتامبر ۲۰۲۳ است و واحد مشاهده در این پژوهش، هر Review ثبت‌شده است. محدودیت‌های اصلی شامل نمونه‌گیری از کل داده‌ها، احتمال وجود داده‌های ناقص یا سوگیری کاربران و عدم امکان استنتاج علی از روابط مشاهده‌شده است.

- ممیزی ساختار داده:

مجموعه Reviews شامل اطلاعات مربوط به نظرات کاربران، از جمله امتیاز، عنوان، متن Review، شناسه کاربر و محصول، زمان ثبت نظر، وضعیت خرید تأییدشده و تعداد رأی‌های مفید است. در این پژوهش، متغیر `helpful_vote` به‌عنوان متغیر هدف در تحلیل‌ها در نظر گرفته شده است. مجموعه Metadata نیز شامل اطلاعات توصیفی محصولات، مانند عنوان، دسته‌بندی، میانگین امتیاز، تعداد امتیازها، قیمت و ویژگی‌های محصول است.

به‌منظور کاهش حجم محاسبات، تعداد ۱۰۰ هزار Review با روش Reservoir Sampling به‌صورت تصادفی انتخاب شده‌اند. سپس Metadata مربوط به محصولات موجود در نمونه Reviews، بر اساس شناسه یکتای `parent_asin` استخراج شده است.

مجموعه Metadata استخراج‌شده شامل ۵۵٬۹۰۲ ردیف و ۱۶ ستون است.

- ممیزی کیفیت:

- در دیتاست Reviews، 141 ردیف دارای متن خالی یا نامعتبر شناسایی و در مرحله‌ی پاک‌سازی حذف شدند. بررسی داده‌های تکراری نشان داد که 7 ردیف تکراری کامل در Reviews وجود دارد؛ همچنین 20 مورد تکرار در زوج کاربر–محصول مشاهده شد. ستون قیمت بررسی و به یک متغیر عددی به نام `price_numeric` تبدیل شد. تمام قیمت‌های غیرگمشده با روش تبدیل انتخاب‌شده قابل تبدیل بودند؛ با این حال، 21,893 مقدار قیمت گمشده وجود داشت. برای شناسایی مقادیر پرت، روش دامنه‌ی بین چارکی (IQR) روی متغیرهای عددی اجرا شد؛ در

Reviews، تعداد 7,825 مقدار پرت در `helpful_vote` و 452 مقدار پرت در `timestamp` شناسایی شد. در Metadata نیز 2,860 مقدار پرت در `price_numeric`، تعداد 2,473 مقدار در `average_rating` و 6,828 مقدار در `rating_number` شناسایی شدند. با توجه به اینکه مقادیر پرت می‌توانند بیانگر ویژگی‌های واقعی محصولات یا Reviewها باشند، هیچ‌یک صرفاً بر اساس معیار IQR حذف نشدند و تصمیم‌گیری درباره‌ی حذف آن‌ها به بررسی معنایی و تحلیل‌های بعدی موکول شد.

- تحلیل اکتشافی تک متغییره: انجام شد.

در این مرحله، توزیع و ویژگی‌های آماری متغیرهای اصلی دیتاست شامل Rating، Helpful Votes، Verified Purchase، طول متن Review و ویژگی‌های محصولات بررسی شد. برای متغیرهای عددی، شاخص‌های توصیفی مانند میانگین، میانه، حداقل، حداکثر و پراکندگی محاسبه شدند. همچنین، با استفاده از نمودارهای هیستوگرام و میله‌ای، شکل توزیع متغیرها و فراوانی مقادیر آن‌ها مورد بررسی قرار گرفت. برای متغیرهای دارای توزیع چوله، از مقیاس لگاریتمی یا محدودسازی بصری محور نمودار استفاده شد.

- تحلیل اکتشافی چند متغییره: انجام شد.

در این مرحله، روابط میان متغیرهای اصلی Reviewها با هدف بررسی عوامل مرتبط با Helpful Votes مورد مطالعه قرار گرفت. ارتباط Rating، طول متن Review و وضعیت Verified Purchase با تعداد رأی‌های مفید از طریق گروه‌بندی و مقایسه‌ی شاخص‌های آماری بررسی شد. همچنین، ماتریس همبستگی Spearman برای بررسی شدت و جهت روابط میان متغیرهای عددی محاسبه و با نمودار Heatmap نمایش داده شد. این تحلیل امکان شناسایی ارتباط‌های احتمالی میان ویژگی‌های Review و میزان مفید تلقی شدن آن‌ها را فراهم کرد.

.

- تعریف خطر نشت اطلاعات:

نشت اطلاعات زمانی رخ می‌دهد که اطلاعاتی از داده‌های اعتبارسنجی یا آزمون، یا اطلاعاتی که در زمان پیش‌بینی در دسترس نیستند، به‌طور مستقیم یا غیرمستقیم وارد فرایند آموزش مدل شوند.
در پروژه‌ی حاضر، استفاده از متغیرهایی که مستقیماً با برچسب هدف `helpful_vote` مرتبط هستند یا اطلاعات آینده را افشا می‌کنند، می‌تواند باعث ایجاد نشت اطلاعات شود. همچنین، انجام پیش‌پردازش‌هایی مانند استانداردسازی یا انتخاب ویژگی بر روی کل داده پیش از تقسیم Train و Test می‌تواند موجب انتقال اطلاعات مجموعه‌ی آزمون به فرایند آموزش شود. برای جلوگیری از این مسئله، ابتدا داده‌ها به مجموعه‌های آموزش و آزمون تقسیم می‌شوند و مراحل یادگیری پیش‌پردازش فقط بر داده‌های آموزش برازش می‌شوند.
با توجه به ماهیت داده‌ها، تقسیم‌بندی زمانی یا گروهی بر اساس محصول یا کاربر نیز می‌تواند در صورت تطابق با هدف پیش‌بینی، از انتقال اطلاعات بین مجموعه‌ها جلوگیری کند. در نهایت، مجموعه‌ی آزمون باید تنها برای ارزیابی عملکرد نهایی مدل استفاده شود و در فرایند آموزش یا انتخاب مدل دخالت نداشته باشد.

- تعریف خط مبنا: پیش‌بینی تعداد رأی‌های مفید هر نقد با استفاده از مقدار ثابتِ برابر با میانگین تعداد رأی‌های مفید در داده‌های آموزشی.
- سوال نهایی: آیا ترکیب ویژگی‌های متنی نقدها و اطلاعات ساخت‌یافته‌ی نقد و محصول می‌تواند دقت پیش‌بینی تعداد رأی‌های مفید را نسبت به استفاده‌ی جداگانه از هر منبع اطلاعاتی بهبود دهد؟

الزامات مسیر ب:

- ممیزی اجزای چندوجهی:

- در این مرحله، اجزای چندوجهی موجود در دیتاست و نوع اطلاعات قابل استفاده در تحلیل شناسایی شدند.داده‌ها شامل چندین نوع اطلاعات هستند: متن Reviewها، امتیاز کاربران، تصاویر احتمالی، زمان ثبت Review و ویژگی‌های مرتبط با محصولات.اطلاعات متنی و امتیازدهی در جدول Reviews و مشخصات محصولات در جدول Metadata ذخیره شده‌اند.
همچنین، شناسه‌های کاربر و محصول امکان شناسایی تعاملات میان کاربران و محصولات را فراهم می‌کنند.ستون تصاویر نیز از نظر وجود محتوای تصویری در Reviewها مورد توجه قرار گرفت.
با بررسی ساختار ستون‌ها و نوع داده‌ها، اجزای اطلاعاتی موجود و نقش آن‌ها در تحلیل مشخص

شدند.این ممیزی، مبنایی برای بررسی میزان دسترس‌پذیری هر مودالیتی و انتخاب ویژگی‌های مناسب در مراحل بعدی پروژه فراهم کرد.

- تحلیل دسترسی پذیری هر وجه:

در این مرحله، ساختار دیتاست Reviews و Metadata و ستون‌های موجود در هر یک بررسی شد.اطلاعات موجود شامل متن Reviewها، امتیاز کاربران، تصاویر احتمالی، زمان ثبت Review، شناسه کاربر و محصول و ویژگی‌های مرتبط با محصولات است.همچنین، نوع داده‌ها و مقادیر گمشده در ستون‌های مختلف بررسی شدند.جدول Reviews شامل اطلاعات مربوط به تجربه و نظر کاربران است، در حالی که جدول Metadata ویژگی‌های محصولات را در بر می‌گیرد.ارتباط میان دو جدول از طریق شناسه `parent_asin` برقرار می‌شود.در نتیجه، منابع اطلاعاتی موجود و ساختار آن‌ها برای مراحل بعدی تحلیل و مدل‌سازی شناسایی شدند.

- ممیزی متن: انجام شد.
- طراحی تقسیم بدون نشت:

برای ارزیابی معتبر مدل، داده‌ها بر اساس زمان ثبت Reviewها مرتب و به‌صورت زمانی تقسیم شدند.70٪ داده‌های قدیمی‌تر برای آموزش، ۱۵٪ برای اعتبارسنجی و ۱۵٪ جدیدترین داده‌ها برای آزمون در نظر گرفته شدند. این روش امکان ارزیابی مدل روی Reviewهای جدیدتر را فراهم می‌کند.تقسیم تصادفی ممکن است باعث حضور Reviewهای یک محصول در مجموعه آموزش و آزمون و در نتیجه ارزیابی خوش‌بینانه شود.

محتوای فایل کارت پروژه

1.

- **مسیر پروژه:** مسیر ب — Amazon Reviews’23
- **زیرمجموعه‌ی انتخاب‌شده:** Beauty & Personal Care.

2.

- **عنوان موقت:** شناخت و پیش‌بینی میزان مفیدبودن نقدهای محصولات زیبایی و مراقبت شخصی در آمازون

.3

- در فروشگاه‌های اینترنتی، کاربران برای تصمیم‌گیری درباره‌ی خرید محصولات از نقدها و تجربه‌های خریداران قبلی استفاده می‌کنند. بااین‌حال، تعداد زیاد نقدها و تفاوت کیفیت آن‌ها باعث می‌شود پیدا کردن نقدهای واقعاً مفید دشوار باشد.
- امتیاز ستاره‌ای یک نقد یا محصول لزوماً نشان نمی‌دهد که آن نقد تا چه اندازه برای خریداران دیگر اطلاعات مفید فراهم می‌کند. برای مثال، ممکن است یک نقد پنج‌ستاره صرفاً جمله‌ای کوتاه مانند «عالی بود» داشته باشد، درحالی‌که یک نقد سه‌ستاره با توضیح دقیق درباره‌ی کیفیت، نحوه‌ی استفاده و نقاط ضعف محصول، اطلاعات بسیار بیشتری در اختیار خریدار قرار دهد.
- در مجموعه‌داده‌ی Amazon Reviews'23، تعداد رأی‌های مفیدبودن نقد (Helpful Votes) نیز ثبت شده است. این متغیر می‌تواند به‌عنوان یک شاخص رفتاری برای بررسی میزان مفید تلقی‌شدن یک نقد توسط کاربران دیگر استفاده شود.
- هدف این پروژه بررسی ویژگی‌هایی است که با تعداد رأی‌های مفید یک نقد ارتباط دارند و ارزیابی این موضوع است که آیا می‌توان با استفاده از متن نقد و اطلاعات ساخت‌یافته‌ی محصول و نقد، تعداد رأی‌های مفید را پیش‌بینی کرد. این پژوهش قرار نیست ثابت کند که یک ویژگی مشخص باعث مفیدتر شدن نقد می‌شود؛ بلکه هدف آن شناسایی روابط آماری، الگوها و توان پیش‌بینی ویژگی‌های مختلف است.

.4

- **واحد تحلیل و پیش‌بینی:** هر مشاهده در این پژوهش یک نقد منفرد ثبت‌شده برای یک محصول است که تعداد رأی‌های مفید آن پیش‌بینی می‌شود.
- شناسه‌های کاربر و محصول برای اتصال داده‌ها و طراحی تقسیم‌بندی استفاده می‌شوند و استفاده از آن‌ها به‌عنوان ویژگی مدل، با توجه به خطر نشت اطلاعات، بررسی خواهد شد.

.5

- **جامعه‌ی مورد مطالعه:** تمامی نقدهای ثبت‌شده برای محصولات دسته‌ی Beauty & Personal Care در مجموعه‌داده‌ی Amazon Reviews'23.
- **دامنه‌ی پژوهش**: بررسی و پیش‌بینی تعداد رأی‌های مفید (Helpful Votes) نقدهای این دسته از محصولات، با استفاده از ویژگی‌های متنی نقدها و اطلاعات ساخت‌یافته‌ی نقد و محصول.

.6

- کدام ویژگی‌های متنی نقدها و ویژگی‌های مرتبط با محصولات با تعداد رأی‌های مفید دریافت‌شده توسط نقدهای محصولات دسته‌ی Beauty & Personal Care در آمازون ارتباط دارند و تا چه اندازه می‌توان تعداد این رأی‌ها را با ترکیب اطلاعات متنی و ساخت‌یافته پیش‌بینی کرد؟ بخش تحلیلی(بررسی رابطه‌ی ویژگی‌های نقد و محصول با تعداد رأی‌های مفید.) بخش پیش‌بینی(ساخت مدل‌هایی برای پیش‌بینی تعداد رأی‌های مفید با استفاده از اطلاعات موجود.)

.7

- **متغیر هدف:** تعداد رأی‌های مفید نقد (Helpful Votes).
- **نوع متغیر:** عدد صحیح نامنفی و از نوع شمارشی (Count).

.8

- ابتدا دو مدل ساده می‌سازیم که تعداد رأی‌های مفید را برای همه‌ی نقدها برابر با میانگین یا میانه‌ی رأی‌های مفید در داده‌ی آموزش پیش‌بینی کنند. سپس عملکرد مدل‌های پیچیده‌تر را با این دو مدل مقایسه می‌کنیم.

.9

- **MAE:** میانگین مقدار اختلاف پیش‌بینی مدل با مقدار واقعی؛ تفسیر ساده‌ای دارد و برحسب تعداد رأی است.
- **RMSE**: مشابه MAE است، اما خطاهای بزرگ را بیشتر جریمه می‌کند.

- **R^2**: نشان می‌دهد مدل چه میزان از تغییرات تعداد رأی‌های مفید را توضیح می‌دهد؛ هرچه به ۱ نزدیک‌تر باشد بهتر است.
- **انتخاب معیار**: MAE معیار اصلی و RMSE معیار مکمل خواهد بود؛ انتخاب نهایی با بررسی توزیع داده و مقایسه‌ی عملکرد مدل‌ها انجام می‌شود. در صورت نامتوازن بودن رأی‌ها، عملکرد در زیرگروه‌ها نیز بررسی خواهد شد.

.10

- تقسیم داده با توجه به هدف ارزیابی مدل، در سه حالت قابل بررسی است: تقسیم تصادفی نقدها، تقسیم گروهی بر اساس محصول و تقسیم زمانی. انتخاب روش نهایی باید با سناریوی پیش‌بینی واقعی هماهنگ باشد تا از نشت اطلاعات و ارزیابی خوش‌بینانه جلوگیری شود.

.11

- مهم‌ترین خطر، نشت اطلاعات از داده‌های آزمون به مدل است؛ مثلاً استفاده از helpful_vote یا اطلاعاتی که هنگام پیش‌بینی در دسترس نیستند. همچنین، ویژگی‌سازی و پیش‌پردازش نباید پیش از تقسیم داده انجام شود و جداسازی کاربران یا محصولات باید متناسب با هدف ارزیابی باشد. تمام مراحل یادگیری پیش‌پردازش فقط روی داده‌ی آموزش انجام شده و سپس روی اعتبارسنجی و آزمون اعمال می‌شوند.

.12

- در این بخش، متن نقدها برای کشف الگوهای پنهان و گروه‌بندی نقدهای مشابه بررسی می‌شود.ابتدا متن‌ها با روش TF-IDF به بردارهای عددی تبدیل شده و سپس با الگوریتم K-Means خوشه‌بندی می‌شوند.با بررسی نقدهای نمونه‌ی هر خوشه، موضوعات و الگوهای پرتکرار شناسایی خواهند شد.در نهایت، تفاوت امتیازها و تعداد

رأی‌های مفید در خوشه‌ها بررسی می‌شود؛ بدون اینکه خوشه‌ها لزوماً معادل دسته‌بندی معنایی قطعی باشند.

.13

- در بخش توسعه‌یافته‌ی پروژه، تحلیل چندوجهی با بررسی هم‌زمان متن نقدها و اطلاعات ساخت‌یافته‌ی نقد و محصول انجام می‌شود. عملکرد مدل در سه حالت Structured-only، Text-only و Combined مقایسه می‌شود تا ارزش افزوده‌ی ترکیب منابع اطلاعاتی مشخص شود.

.14

- **سوگیری در معیار مفیدبودن نقد:** تعداد رأی‌های مفید لزوماً نشان‌دهنده‌ی کیفیت واقعی یک نقد نیست. نقدهای محصولات محبوب یا نقدهایی که مدت بیشتری از انتشار آن‌ها گذشته، ممکنه به دلیل بازدید بیشتر یا فرصت طولانی تر، رأی‌های بیشتری دریافت کرده باشند.
- **سوگیری در داده‌ها:** داده‌های عمومی آمازون ممکن است نماینده‌ی تمام کاربران و خریداران این پلتفرم نباشند. همچنین، تمرکز پروژه بر دسته‌ی Beauty & Personal Care باعث می‌شود نتایج لزوماً به سایر دسته‌های محصولات قابل تعمیم نباشند.
- **حریم خصوصی کاربران:** با وجود عمومی بودن داده‌ها، اطلاعات مربوط به کاربران با احتیاط استفاده می‌شود. شناسه‌های کاربران فقط برای بررسی ساختار داده و طراحی روش مناسب تقسیم داده‌ها به بخش‌های آموزش و آزمون به کار می‌روند. هیچ تلاشی برای شناسایی هویت واقعی کاربران انجام نخواهد شد.
- **محدودیت در تفسیر نتایج:** هدف پروژه بررسی الگوها و پیش‌بینی مفیدبودن نقدهاست، نه اثبات رابطه‌ی علت و معلولی میان ویژگی‌های نقد و تعداد رأی‌های مفید آن. بنابراین، نتایج مدل‌ها باید به‌عنوان روابط آماری و الگوهای مشاهده‌شده تفسیر شوند.

- **محدودیت‌های استفاده از داده**: پیش از انتشار داده‌ها، کد یا نتایج پروژه، شرایط استفاده و مجوز مجموعه‌داده بررسی خواهد شد تا از استفاده و انتشار آن در چارچوب مجاز اطمینان حاصل شود.